

공동(위탁)연구기관

한국노동연구원(KLI) 연구 진행현황 및 계획

연구 목표

- 정부부처가 정책이 집계 및 분포적 효과에 미치는 효과를 분석하는 모형을 상대적으로 손쉽게 확인할 수 있도록 하는 플랫폼 구축
- 한국노동연구원은 이를 위해 다음을 목표로 연구를 수행하여 「AI·데이터 기반 재정·경제 디지털트윈 플랫폼 개발」 연구 성공에 기여하고자 함
 - 1. 이질적 경제주체 동태적확률일반균형 모형 구축: 정책파급효과 매커니즘 파악 및 반사실적 분석 가능
 - 2. 거시 행위자기반모형 노동시장 의사결정 부분 개선
 - 3. 집계변수와 분포적 정보(ex: 연령별 고용률, 소득분포 등)를 모두 활용하여 추정하는 실증분석 모형 추정: 과정은 블랙박스지만 결과를 더 손쉽게 볼 수 있음
 - 4. 기계학습 기반 모형 구축 및 개량: 전망 결과에 도움

연차별 연구 내용 및 예상 결과물 - 1차& 2차

1차(2022년)	
계획	1. fVAR 모형: 재정지출 충격의 동태적 및 분포적 고용 효과 분석
	2. Horce Racing: 정형&비정형자료, 전통적&기계학습모형을 모두 활용-> 노동시장 주요변수 예측
결과물	1. 다양한 용도로 활용 가능한 fVAR 모형 구축 및 정부지출의 비대칭적 고용효과 발견
	2. Support Vector Regressor/Random Forest Regressor>전통적 회귀분석
2차(2023년, 올해)	
2차년 연구계획	1. 이질적 경제주체 동태적확률일반균형(HA - DSGE) 모형 구축
	2. Macro-ABM 노동시장 의사결정 부분 개량
	3. 전망모형 성과 개선 작업
전년도 성과물 개선작업	1. fVAR: 기술적 보완, 소득, 소비분포로의 확장, 고용전망 등에 활용
	2. 학술적 측면 개발: fLP, fLP - DiD 등으로의 확장 고려 중
	3. 고용위기 시 기계학습 모형의 MSE 성과를 개선하기 위한 방법론 개발 중
기대 결과물	1. 빠르게 계산될 수 있는 HA-DSGE 모형 구축
	2. 정합성 부분을 보완한 Macro-ABM 모형 구축
	3. 성과가 개선된 기계학습 전망모형 구축
	4. 실용적으로 전망작업에서 참조가 가능한 fVAR 모형 구축

연차별 연구 내용 및 예상 결과물 - 3차 이후

- 주요 연구내용

- HA - DSGE 모형 지속 보수 및 개발
- Macro - ABM 노동시장 의사결정 부문 Refinement
- 정형 및 비정형데이터 활용 모형 성과개선
- fVAR, fLP 등 실증모형 지속적으로 유지.보수

- 주요 과제: 세분화된 정책 고려

- 분야별 재정지출 효과 분석: ABM이 더 효율적일 수 있음. 이를 위한 정합성 개선
- DSGE: 성질별 지출까진 가능할 것으로 보임
- 실증분석 부분: 분야별 재정지출 효과 분석 시 (f)VAR 등은 불안정한 결과를 계속 보임

연구 개발 진행 경과 1. HA – DSGE 모형

- 현재 단계: 경제전반적 충격이 없는 경제에서의 소비-저축-노동공급 및 탐색마찰이 존재하는 경제 모형 구축

	Huggett: Consumption, Saving & Labor Supply		Krusell, Mukoyama and Sahin: Precautionary saving & Search Friction	
	연속시간(MATLAB)	이산시간(MATLAB)	연속시간(MATLAB)	이산시간(FORTRAN)
	(Finite Difference Method)	(Golden Section + VFI)	(Finite Difference Method)	(Golden Section + VFI)
# of Grids	시간(초)	시간(초)	시간(초)	시간(초)
100	0.23	6.94	1.96	Haven't tried, but hard to expect that it would be much faster
1000	0.35	67.6	6.43	
10000	1.89	739.14	17.47 (# of grids: 3000)	

참조: 이산시간 vs. 연속시간 모형

- Discrete Time: Solve for Today & Tomorrow

Given prices $\{w, r\}$, the each agent solves the Bellman equation optimally:

$$V(a, x) = \max_{\{c, a'\}} \left\{ u(c) + \beta \int V(a', x') dF(x'|x) \right\} \quad (5)$$

subject to

$$\begin{aligned} c + a' &= wx + (1 + r)a \\ \log x' &= \rho_x \log x + \sigma_\epsilon \epsilon' \end{aligned}$$

- Continuous Time: Faster as it solves for Today only!

$$\rho v(a, x) = \max_c \left\{ u(c) + v_a(a, x)da + v_x(a, x)m(x) + \frac{\sigma^2(x)}{2} v_{xx} v(a, x) \right\} \quad (6)$$

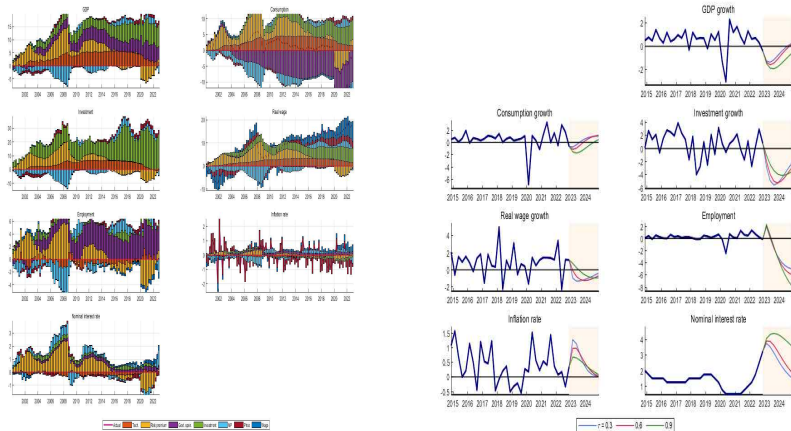
where

$$da = wx + ra - c$$

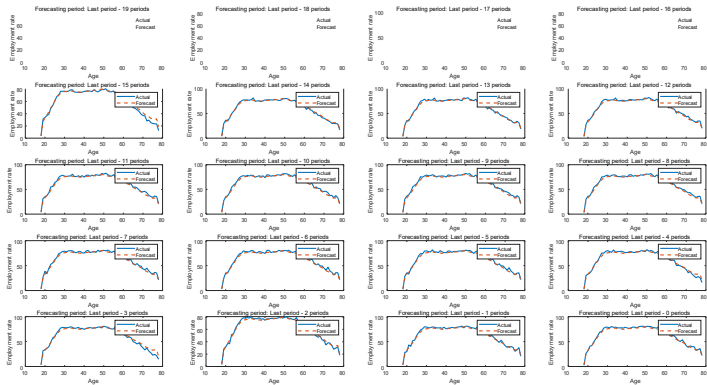
참조 2: Alternative & Go Further

- 이산시간
 - Auclert et al.(2021): Sequence – Space Jacobian(SSJ)
 - Fernández-Villaverde et al.(2023): Deep learning
- HA + Smets and Wouters
 - Bayer et al.(Forthcoming): BAYesian Solution and Estimation (BASE)
- Each role of model
 - HA(NK): Analyzing policy propagation
 - HANK + SW: Forecasting power

2. Representative Agent New Keynesian with many shocks & frictions – Keep checking & revising



연구 개발 진행 경과 3. fVAR 전망작업



연구 개발 진행 경과 4-1. 기계학습 모형 개량

- Machine learning model을 이용한 노동시장 주요 변수 예측 관련 금년도 개발 계획
 - Step 1: 노동시장 주요 변수 세 가지(경제활동참가율, 고용률, 실업률)를 예측하는데 있어서 가장 효과적인 모형은 무엇인지를 conventional regression models, traditional machine learning models, deep learning model 간에 비교
 - Step 2: 가장 나은 performance를 보이는 모형을 찾은 후, 해당 모형에 대해서 데이터를 grouping하여 가장 나은 예측 performance를 보이는 setting을 찾고자 함
 - 기본적으로 노동시장 포함 모든 정형 데이터(structured data)를 이용
 - step 1에서 찾은 best performing model에 기반하여, 각 데이터들을 성격이나 출처 등에 따라 grouping하여(e.g. 산업 데이터, 경기 전망 데이터, 건설 데이터, 노동 데이터, 수출 데이터, 수입 데이터, 에너지 데이터 등) 각 group을 추가하거나 제거해 가면서 performance 비교
 - Step 3: 가장 나은 performance를 보이는 모형과 데이터 세팅을 찾은 후, 이를 바탕으로 모형을 fine tuning 해가면서 best performance를 탐색


연구 개발 진행 경과 4-2. 기계학습 모형 개량

- Machine learning model을 이용한 노동시장 주요 변수 예측 관련 금년도 계획과 연결된 후속 연도 개발 계획
 - Point 1: best performing model의 예측력은 어느 정도인지 실제 평가
 - Point 2: best performing model의 예측과 관련하여 과거 큰 경기 변동기(2007년 금융위기, 2020년 코로나 관련 경기 변동 등)에서 MSE(mean squared error)로 평가한 예측력이 크게 떨어지는지 판단
 - 만일 큰 경기 변동기에 예측력이 지속적으로 떨어진다면 경기 불황기와 호황기에 다른 모형을 적용해야 할 가능성이 있음
 - 다른 모형을 찾아야 할 필요가 있다는 판단이 든다면 Benford analysis 등 phase or regime change가 발생하는 시점을 식별하는 작업을 후속년도에 시행
 - 두세 가지 phase에 대해서 각각 best performing하는 model을 탐색

연구 개발 진행 경과 4-3. 기계학습 모형 개량

• 노동시장 지표들만을 가지고 돌린 예측 결과

훈련데이터 양의 변화에 따른 RMSE 변화 (1개월 단위)



연구 개발 진행 경과 4-4. 기계학습 모형 개량

• 노동시장 지표들만을 가지고 돌린 예측 결과(MSE)

		경제활동참가율	고용률	실업률	취업자 수
Conventional	Linear Regression	0.54	0.47	0.65	272.04
	Lasso with Least Angle Regression	0.45	0.33	0.52	223.62
Traditional Machine Learning	AdaBoost Regressor	0.35	0.31	0.41	188.45
	Decisiontree Regressor	0.37	0.35	0.49	246.11
	Randomforest Regressor	0.31	0.28	0.39	163.38
	GradientBoosting Regressor	0.33	0.27	0.39	166.25
	SupportVector Regressor	0.35	0.31	0.44	295.15
	LGBM Regressor	0.32	0.28	0.36	160.81
	ExtraTreeRegressor	0.29	0.29	0.38	158.89
Deep Learning	FeedForward Network	0.32	0.28	0.42	165.78

Few Basic Discussions:

- Macro ABM & DSGE

- Macro ABM: 확장성& 유연성, 분야별 재정지출 모형화 작업이 DSGE보다 상대적으로 용이할 수 있음. 정합성 보완 문제
- DSGE: 기본적으로 고정점(fixed point)을 찾는 문제: 이것에서 대다수의 장단점이 유래됨

- 모형 내 설명 vs. 전망은 다른 문제

- 질문에 따라 다름
- 정부지출을 1원 늘리면 일자리/소비 등에 어떤 효과를 미칠 것인가?
- 내년 취업자 수와 경제성장이 어떻게 될 것인가?

- 분야별 정부지출 효과 분석

- 재화/서비스 등으로 구분하는 것도 방법. 12대/16대 분야 분석은 직접적이지만 더 나은 방법을 찾아봐야 할 수 있을 것

향후 계획

- 이질적 경제주체 뉴케인지언(HANK)
 - Bayer, Born and Luetticke(Forthcoming): HANK+Smets and Wouters
 - Step by Step: 이질적 경제주체 뉴케인지언(HANK) 모형을 먼저 구축하고자 함
- Horse racing & fVAR
 - 성과개선을 위한 지속적 유지보수
- 대표적 경제주체 뉴케인지언(RANK) 모형
 - 뉴욕연준은행(NY-FED) 모형 참조하여 개선 가능

기대 효과

- 빠른 시간 내에 계산이 가능한 HA – DSGE 모형 구축
- 참조할 수 있는 전망모형 구축
 - Horse Racing: 대표적으로 활용되는 전망모형의 성과를 매기 비교하여 최적 성과 모형 도출
 - fVAR: HA – DSGE 모형 결과를 더 용이하게 참조할 수 있음
- 부속결과물([NY-FED 게시물 링크\(클릭\)](#), 0616 자료)

Forecast Period	2023		2024	
Date of Forecast	Jun 23	Mar 23	Jun 24	Mar 24
GDP growth (Q4/Q4)	1.0 (-1.9, 4.0)	0.2 (-3.7, 4.1)	0.7 (-4.2, 5.7)	0.0 (-5.0, 4.0)
Core PCE inflation (Q4/Q4)	3.7 (3.3, 4.2)	3.5 (2.9, 4.1)	2.5 (1.6, 3.3)	3.0 (2.2, 3.9)
Real natural rate of interest (Q4)	2.2 (1.0, 3.5)	2.0 (0.7, 3.3)	1.8 (0.3, 3.2)	1.7 (0.1, 3.1)

Source: Authors' calculations.

Notes: This table lists the forecasts of output growth, core PCE inflation, and the real natural rate of interest from the June 2023 and March 2023 forecasts. The numbers outside parentheses are the mean forecasts, and the numbers in parentheses are the 68 percent bands.

This fairly dramatic change in the forecasts is mostly due to one new piece of information: SPF long-term inflation expectations have dropped by about 45 basis points in 2023:Q1 relative to 2022:Q4, a very large change by historical standards. The model interprets this change in long run inflation expectations as resulting from higher expected total factor productivity (TFP) growth, which rationalizes both the lower inflation and the higher output projections. Were it not for this data point,